

Spiking Convolutional Deep Belief Networks for Unsupervised High Level Feature Extraction and Pattern Reconstruction

Master Thesis of

David Zimmerer


Department of Computer Science
Institute for Anthropomatics and Robotics
and
FZI Research Center for Information Technology

Reviewer:	Prof. Dr.–Ing. R. Dillmann
Second reviewer:	Prof. Dr.–Ing. J. M. Zöllner
Advisor:	M. Sc. Jacques Kaiser

Research Period: 06. July 2016 – 05. January 2017

Spiking Convolutional Deep Belief Networks for Unsupervised High Level Feature Extraction and Pattern Reconstruction

by
David Zimmerer



Master thesis
in January 2017

Master thesis, FZI
Department of Computer Science, 2017
Gutachter: Prof. Dr.–Ing. R. Dillmann, Prof. Dr.–Ing. J. M. Zöllner

Affirmation

Ich versichere wahrheitsgemäß, die Arbeit selbstständig angefertigt, alle benutzten Hilfsmittel vollständig und genau angegeben und alles kenntlich gemacht zu haben, was aus Arbeiten anderer unverändert oder mit Abänderungen entnommen wurde.

Karlsruhe,
in January 2017

David Zimmerer

Abstract

Extracting high level features in data automatically can benefit various tasks such as classification and prediction. Deep belief networks allow to build feature extractors in an unsupervised manner. Utilizing a convolutional multilayered architecture can further improve the quality of the features on compositional data and allow a more abstract representation. Most architecture perform operations in discrete time steps and do not utilize a continuous information processing similar to the brain, which could lead to faster response times and a lower power consumption. In this thesis we propose different biologically inspired architectures to build and train a spiking deep belief network with a convolutional architecture. Two different training algorithms are presented. The first approach trains the network in discrete time steps and the resulting network is afterwards transformed into a spiking neural network. The second approach trains a spiking network directly with an adapted spike time dependent plasticity learning rule and weight synchronization. Both algorithms are evaluated on different discrete and event-based datasets. On the different datasets the algorithms are able to discriminate classes with high accuracy without any modification of the learning rules, thus indicating an adaptive feature extraction algorithm. By comparing both approaches it becomes apparent that by introducing lateral inhibitory connections the directly trained algorithm is able to extract more discriminative features.

Abstrakt

Die automatische Extraktion von "High-Level Features" unterstützt und erleichtert Aufgaben wie Klassifikation und Prädiktion. Mit Hilfe von Deep Belief Networks können solche Feature Extraktoren unüberwacht gelernt werden. Durch eine vielschichtige Convolutional Architektur kann die Feature Qualität auf kompositionellen Daten weiter verbessert werden und eine abstraktere Repräsentation ermöglicht werden. Die meisten Architekturen arbeiten, im Gegensatz zum Gehirn, in diskreten Zeitschritten und nutzen keine kontinuierliche Informationsverarbeitung, was zu schnelleren Verarbeitungszeiten und einer niedrigeren Leistungsaufnahme führen könnte. In dieser Arbeit werden verschiedene biologisch motivierte Architekturen vorgestellt, die es ermöglichen ein Convolutional Spiking Deep Belief Network aufzubauen und zu trainieren. Es werden zwei verschiedene Ansätze präsentiert. Der erste Ansatz trainiert ein Netzwerk in diskreten Zeitschritten und wandelt danach das trainierte Netzwerk in ein Spiking Netzwerk um. Der zweite Ansatz trainiert direkt ein Spiking Netzwerk mit einer angepassten Version der "Spike-Time dependent plasticity" Lern-Regel mit Parameter-Synchronization. Die Ansätze werden auf verschiedenen diskreten und Event-basierten Datensätzen evaluiert. Beide Ansätze erreichen auf den verschiedenen Datensätzen eine hohe Klassifikationsgenauigkeit ohne die zugrunde liegenden Lern-Regel zu verändern, was auf einen adaptionsfähig Feature-Extraktions Algorithmus schließen lässt. Der Vergleich der beiden Ansätze legt nahe, dass aufgrund von lateral-hemmenden Verbindungen der zweite Ansatz diskriminativere Features extrahieren kann.

Abbreviations

ANN	Artificial Neural Network
BM	Boltzmann Machine
CD	Contrastive Divergence
CNN	Convolutional Neural Network
COBA	Conductance-Based
CUBA	Current-Based
DBN	Deep Belief Network
DVS	Dynamic Vision Sensor
EBM	Energy-Based Model
eCD	Event-driven Contrastive Divergence
HCS	High Conductance State
LIF	Leaky Integrate-and-Fire
LTD	Long-Term Depression
LTP	Long-Term Potentiation
MCM	Markov Chain Monte Carlo
MLP	Multilayer Perceptron
MRF	Markov Random Field
NN	Neural Network
PGM	Probabilistic Graphical Model
pCD	Persistent Contrastive Divergence
PSP	Post Synaptic Potential
RBM	Restricted Boltzmann Machine
RV	Random Variable

SNN	Spiking Neural Network
STDP	Spike Time Dependent Plasticity

$\langle \cdot \rangle$	Expected Value of \cdot
-------------------------	---------------------------

$\sigma(\cdot)$	<i>sigmoid</i> (\cdot)
-----------------	----------------------------

Contents

1	Introduction	1
1.1	Motivation	1
1.2	Problem Statement	2
1.3	Overview	2
2	Background	3
2.1	Probabilistic Graphical Models	3
2.1.1	Bayesian Networks	3
2.1.2	Markov Random Fields	5
2.1.3	Energy-Based Models	5
2.1.4	Sampling	6
2.2	Neural Networks	7
2.2.1	Natural Neural Networks	8
2.2.2	Artificial Neural Networks	10
2.2.3	Spiking Neural Networks	25
3	Related Work	35
3.1	Convolutional RBM	35
3.2	Sampling in SNNs	36
3.3	Artificial to Spiking Neural Network Conversion	39
3.4	Event-Driven CD	40
4	Approach	43
4.1	Convolutional Architecture in Spiking Neural Networks	43
4.2	Conversion	44
4.2.1	Convolutional DBNs	44
4.2.2	Conversion	44
4.3	eCD	47
4.3.1	Convolution in eCD	48
4.3.2	Spiking DBNs	50
5	Implementation	51
5.1	Artificial DBNs	51
5.2	Conversion	52
5.3	eCD	53

6 Experiments & Results	55
6.1 Datasets	55
6.1.1 Stripe Dataset	55
6.1.2 MNIST	56
6.1.3 Poker-DVS	56
6.1.4 Ball-Can-Pen-DVS	57
6.2 Experiments	58
6.2.1 Computational Constrains	58
6.2.2 Conversion	59
6.2.3 eCD	61
6.2.4 Conversion vs. eCD	71
7 Conclusion and Outlook	73
7.1 Future Work	74
7.1.1 Neuromorphic Hardware	74
7.1.2 Biologically Plausible Learning	75
A Appendix	77
A.1 Neuron Parameters	77
A.2 Lateral Inhibition	78
A.3 Spiking DBN Architectures	79
A.4 Synchronous Weight Updates	80
B List of Figures	83
C List of Tables	87
D Bibliography	89